MLOps FTI

從特徵到上線的完整閉環

預測標的：AAPL

預測任務：5 日超額報酬率（相對 SPY）

這個專案解決三個問題

Training-Serving Skew（訓練推論不一致）。 訓練和推論用不同的特徵計算邏輯，模型上線後表現變差。這種情況很常見，因為特徵工程散落在各處，沒有統一管理。

> 💡 **什麼是訓練？什麼是推論？**
>
> - **訓練**：餵資料給模型，讓它學習規律（像學生讀書）
> - **推論**：用訓練好的模型做預測（像學生考試）

退步模型上線。 新模型看起來比舊模型好，但實際上只是過擬合訓練資料。沒有穩定的驗證機制，就無法保證上線的模型真的有進步。

> 💡 **什麼是過擬合？**
> 模型把訓練資料「背起來」了，而不是真的學到規律。就像學生把考古題答案背起來，換個題目就不會了。

流程不可持續。 每次更新模型都要手動跑一堆腳本，時間一久就沒人願意維護。最後模型停在原地，資料也跟著過時。

專案架構

```
yfinance（資料源）
→ Feature Pipeline → Hopsworks Feature Store
→ Training Pipeline → Hopsworks Model Registry
→ Inference Pipeline（Modal 排程）
→ Gradio UI（Hugging Face Spaces）
```

> 💡 **這條鏈路在做什麼？**
>
> - **Feature Pipeline**：抓資料、算特徵（準備食材）
> - **Feature Store**：存特徵的倉庫（冰箱）
> - **Training Pipeline**：訓練模型（煮菜）
> - **Model Registry**：存模型的櫃子（食譜本）
> - **Inference Pipeline**：用模型做預測（上菜）

這條鏈路的核心思想很簡單：**特徵只算一次，訓練和推論共用同一套邏輯。**

Hopsworks 當 Feature Store 和 Model Registry，Modal 負責排程推論，Hugging Face Spaces 跑前端介面。每個環節都有對應的 CI/CD 自動化。

Feature Pipeline：把特徵做對

核心職責

1. 抓取 AAPL、SPY、QQQ、VIX 價格資料
2. 計算技術指標和市場脈絡特徵
3. 寫入 Feature Store 供訓練與推論共用

重點：同一套邏輯，訓練和推論都要用。

實作架構

```
yfinance（資料源）
↓
計算技術指標（RSI, MACD, BB）
↓
Hopsworks Feature Store
```

> 💡 **什麼是特徵？**
> 特徵就是模型的「輸入資料」。比如預測股價，特徵可能是：過去 5 天漲幅、成交量變化、RSI 指標等。好的特徵能讓模型更容易學到規律。

共享模組：避免邏輯分叉

為什麼需要共享？

- `src/features.py` 放一份計算邏輯
- Feature Pipeline 和 Inference Pipeline 都 import 它
- 改一處，兩邊一起生效

這比「特徵很多」更重要。

```
# src/features.py
def calculate_technical_indicators(
    df: pd.DataFrame
) -> pd.DataFrame:
    delta = df["close"].diff()
    gain = delta.clip(lower=0)
        .rolling(14).mean()
    ...
    return df
```

常數集中管理

好處

- 魔術數字集中在 `constants.py`
- 改 RSI 週期？改一個地方就好
- 不用翻遍整個專案找 `14` 出現在哪

時間一久，各處的魔術數字開始不一致，除錯時就很痛苦。

```
# src/constants.py
RSI_PERIOD = 14
MACD_FAST_PERIOD = 12
TRAIN_TEST_SPLIT_RATIO = 0.8
MARKET_TICKERS = {
    "spy": "SPY",
    "qqq": "QQQ",
    "vix": "^VIX"
}
```

> 💡 **什麼是魔術數字？**
> 程式碼裡直接寫死的數字，像 `14` 、 `0.8` 。問題是沒人知道這些數字哪來的、為什麼是這個值。把它們集中管理並命名，像 `RSI_PERIOD = 14` ，程式碼就更容易理解。

Training Pipeline：不只是訓練模型

三個檢查點

1. **時序切分**：不能 shuffle，按時間先後切分
2. **Walk-Forward**：滾動時間窗評估穩定性
3. **Baseline Gating**：只有打敗 baseline 才上傳

避免「單次指標好看但實際不可用」。

```
# 時序切分（正確做法）
split_idx = int(len(X) * 0.8)
X_train = X.iloc[:split_idx]
X_test = X.iloc[split_idx:]

# Walk-Forward 驗證
for fold in range(5):
    train, test = split_fold(fold)
    evaluate(train, test)
```

時序資料不能 shuffle

為什麼？

股票資料有時間順序。用未來的資料訓練、預測過去，模型指標會很好看，但這是作弊。

Walk-Forward 進一步測試不同時間窗的表現，確認模型不是只對特定時期有效。

```
# ✅ 正確做法
split_idx = int(len(X) * 0.8)
X_train, X_test = X.iloc[:split_idx], X.iloc[split_idx:]

# ❌ 錯誤做法—絕對不要用
X_train, X_test = train_test_split(
    X, test_size=0.2
) # 會壞掉
```

> 💡 **什麼是 shuffle？**
> 隨機打亂資料順序。一般機器學習會這樣做，但時間序列資料（如股價）絕對不能！因為時間有先後順序，用「未來」的資料訓練去預測「過去」，等於偷看答案。

Baseline Gating：未達標不上線

機制說明

Baseline 是「不做任何複雜預測」的簡單模型。如果新模型連這個都打不贏，就沒必要上傳到 Model Registry。

這個機制擋掉了很多看起來不錯、實際上退步的模型。

```
mae_pass = metrics["mae"] <= baseline_mae * (1 + tolerance)
rmse_pass = metrics["rmse"] < baseline_rmse
r2_pass = metrics["r2"] > baseline_r2
beats_baseline = mae_pass and rmse_pass and r2_pass
```

> 💡 **什麼是 Baseline？**
> 最簡單的預測方式，比如「直接預測平均值」或「預測永遠不變」。新模型如果連這種笨方法都贏不了，表示模型有問題，不該上線。

Inference Pipeline：自動排程推論

自動化流程

每個交易日台灣時間早上 6 點：

- 系統自動抓最新資料
- 跑推論
- 把預測結果寫回 Feature Store

不需要人為介入。

```
@app.function(
    schedule=modal.Cron("0 22 * * 1-5"),
    timeout=300,
)
def scheduled_inference():
    return run_pipeline()
```

💡 **Cron 是什麼？**

一種排程語法，告訴電腦「什麼時候做什麼」。`"0 22 * * 1-5"` 意思是：每週一到週五的 22:00（UTC）執行。就像設定鬧鐘，每天固定時間響。

CI/CD：讓整個流程可持續

CI（持續整合）

每次改 code 就自動檢查有沒有問題。

CD（持續部署）

檢查通過後自動上線。

層級	內容
CI	Ruff linter + pytest + MyPy 型別檢查
CD	app.py 更新時自動部署到 Hugging Face Spaces
Retraining	每週六自動重訓（GitHub Actions 備援）

💡 什麼是 CI/CD？

- **CI（Continuous Integration，持續整合）**：每次改 code 就自動檢查有沒有問題。像寫完作業自動批改，告訴你哪裡錯了。
- **CD（Continuous Deployment，持續部署）**：檢查通過後自動上線。像批改通過就自動公布答案，不用手動操作。

沒有 CI/CD：改 code → 手動測試 → 手動部署 → 忘了某個步驟 → 出包
有 CI/CD：改 code → 自動檢查 → 自動部署 → 睡覺去

這不是為了炫技，而是為了讓專案能長期運作。資料更新 → 推論 → 週期重訓 → 模型更新 → UI 展示，這個循環跑起來後，維護成本就會大幅降低。

> 💡 **什麼是 linter 和型別檢查？**
>
> - **Linter**：檢查程式碼風格和潛在錯誤（像拼字檢查）
> - **型別檢查**：確保變數型別正確（確保不會把「蘋果」加到「數字」）

結語

模型分數很重要，但不是唯一重要的事。

「可重複」——每次跑 Pipeline 得到一樣的結果。

「可追蹤」——知道每個模型用了什麼資料、哪些特徵。

「可持續」——流程自動化，不需要每天手動操作。

這三件事做到位，模型上線後才不會變成一場災難。

專案原始碼

🔗 **GitHub Repository**: lucashsu95/learn-MLOps-FTI

所有程式碼、Pipeline 腳本、測試案例都在這裡。歡迎參考與討論。

附錄：術語速查表

術語	白話解釋
Feature	特徵，模型的輸入資料（像食材）
Pipeline	流程管線，把多個步驟串起來（像生產線）
Training	訓練，讓模型學習（像學生讀書）
Inference	推論，用模型做預測（像學生考試）
Overfitting	過擬合，把訓練資料背起來而非學到規律（背考古題）
Baseline	基準線，最簡單的預測方式（用來比較新模型有沒有進步）
CI	持續整合，改 code 自動檢查（自動批改作業）
CD	持續部署，檢查通過自動上線（自動公布答案）
Linter	程式碼風格檢查器（拼字檢查）